



**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«САМАРСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ ИМЕНИ АКАДЕМИКА С.П. КОРОЛЕВА
(САМАРСКИЙ УНИВЕРСИТЕТ)»**

ИНСТИТУТ ИНФОРМАТИКИ И КИБЕРНЕТИКИ
Кафедра программных систем

Дисциплина
Системы искусственного интеллекта

ОТЧЕТ
по лабораторной работе № 2

Задача классификации

Выполнили: Фокин Е.А., Сидоров А.О., Павлов В.О., Мергалиев Р.Е., Хасанов Д.И., Клеймёнов А. С., Сальников И.А., группа № 6303-030203D

Проверила: Жданова А.Н.

Самара 2025

ВВЕДЕНИЕ

Целью данной лабораторной работы являлось построение и всесторонняя оценка моделей бинарной классификации для решения задачи прогнозирования согласия клиента на открытие банковского вклада. В ходе работы необходимо было освоить и применить базовые и продвинутые алгоритмы машинного обучения, метрики качества для несбалансированных выборок, а также методы интерпретации и анализа ошибок моделей.

1. Подготовка и предобработка данных

Исходный датасет содержал информацию о клиентах банка, параметрах маркетинговой кампании и макроэкономических показателях. Перед построением моделей была выполнена комплексная предобработка данных.

Этапы предобработки:

1. Удаление дубликатов: Из набора данных было удалено 12 полностью дублирующихся записей, что обеспечило уникальность каждого наблюдения;
2. Обработка скрытых пропусков: Значения 'unknown', представляющие собой скрытые пропуски, были заменены на самое частое значение (моду) в соответствующем категориальном столбце;
3. Преобразование типов данных: Все столбцы типа `object` были преобразованы в категориальный тип для оптимизации использования памяти (сокращение с 6.6+ MB до 3.9 MB) и семантической корректности;
4. Преобразование целевой переменной: Целевая переменная `y` была преобразована из категориального формата (`yes/no`) в числовой (`1/0`) для корректной работы алгоритмов машинного обучения.

Первые 5 строк обработанного датасета:

```
=====
  age      job marital education default housing loan  contact month \
0   56  housemaid married  basic.4y      no      no  no  telephone  may
1   57  services married  high.school    no      no  no  telephone  may
2   37  services married  high.school    no     yes  no  telephone  may
3   40   admin. married  basic.6y      no      no  no  telephone  may
4   56  services married  high.school    no      no  yes  telephone  may

  day_of_week ... campaign pdays previous  poutcome emp.var.rate \
0         mon ...         1    999         0 nonexistent      1.1
1         mon ...         1    999         0 nonexistent      1.1
2         mon ...         1    999         0 nonexistent      1.1
3         mon ...         1    999         0 nonexistent      1.1
4         mon ...         1    999         0 nonexistent      1.1

  cons.price.idx  cons.conf.idx  euribor3m  nr.employed  y
0         93.994         -36.4      4.857      5191.0  0
1         93.994         -36.4      4.857      5191.0  0
2         93.994         -36.4      4.857      5191.0  0
3         93.994         -36.4      4.857      5191.0  0
4         93.994         -36.4      4.857      5191.0  0
=====
```

[5 rows x 21 columns]

Итоговая размерность: (41176, 21)

Рисунок 1 - Пример очищенных данных после предобработки

Обоснование выбора стратегии замены на моду:

Для категориальных данных замена на моду является оптимальной стратегией по следующим причинам:

1. По сравнению с медианой: Медиана неприменима к категориальным данным, так как они не имеют числового порядка;
2. По сравнению с константой: Замена на специальное значение создает искусственную категорию, которая может ввести модель в заблуждение;
3. Преимущества моды: Сохраняет исходное распределение категорий, не создает артефактов, обеспечивает минимальное искажение исходных закономерностей;

Анализ и обработка 'unknown'

Значения 'unknown' являются скрытыми пропусками. Проанализируем их количество.

- Столбец 'job': 330 значений 'unknown' (0.80%)
- Столбец 'marital': 80 значений 'unknown' (0.19%)
- Столбец 'education': 1730 значений 'unknown' (4.20%)
- Столбец 'default': 8596 значений 'unknown' (20.88%)
- Столбец 'housing': 990 значений 'unknown' (2.40%)
- Столбец 'loan': 990 значений 'unknown' (2.40%)

Рисунок 2 - Распределение пропущенных значений ('unknown') по столбцам датасета

Для обеспечения корректной и воспроизводимой обработки признаков был создан единый конвейер (Pipeline) с помощью ColumnTransformer, который выполнял:

1. Масштабирование числовых признаков методом StandardScaler;
2. Кодирование категориальных признаков методом OneHotEncoder.

Это позволило инкапсулировать всю логику предобработки и избежать утечки данных при обучении и валидации моделей.

2. Разбиение данных и стратегия валидации

Для объективной оценки моделей данные были разделены на три выборки в соотношении 60/20/20 (обучающая, валидационная и тестовая соответственно). Было применено стратифицированное разбиение по целевой переменной y для сохранения исходной пропорции классов (~11.3% положительного класса) во всех выборках, что критически важно в условиях дисбаланса. Все случайные процессы были зафиксированы с помощью `random_state=42` для обеспечения полной воспроизводимости экспериментов.

3. Построение и сравнение моделей

На валидационной выборке было проведено сравнение нескольких моделей. В качестве ключевых метрик использовались F1-score (для класса 1), ROC-AUC и PR-AUC, так как они наиболее адекватно отражают качество классификации на несбалансированных данных.

3.1. Базовые модели

1. Logistic Regression: Простая, но надежная линейная модель. Показала $F1\text{-score} = 0.58$, $ROC\text{-AUC} = 0.9359$, $PR\text{-AUC} = 0.5873$;
2. Decision Tree: Для дерева решений с помощью GridSearchCV была подобрана оптимальная глубина ($\text{max_depth}=10$). Модель показала $F1\text{-score} = 0.56$, $ROC\text{-AUC} = 0.8877$, $PR\text{-AUC} = 0.5405$.

Логистическая регрессия была выбрана в качестве baseline, так как продемонстрировала лучшие результаты по всем ключевым метрикам.

4. Продвинутая модель

В качестве продвинутой модели был выбран LightGBM — эффективная реализация градиентного бустинга. Для подбора оптимальных гиперпараметров использовался RandomizedSearchCV, который протестировал 10 случайных конфигураций.

LightGBM (с настроенными параметрами): Модель показала $F1\text{-score} = 0.63$, $ROC\text{-AUC} = 0.9445$, $PR\text{-AUC} = 0.6550$.

Настроенная модель LightGBM продемонстрировала существенное превосходство над baseline по всем метрикам и была выбрана в качестве финальной ("победителя").

Отчет по Логистической регрессии на валидационной выборке:

	precision	recall	f1-score	support
0	0.98	0.86	0.91	7307
1	0.44	0.87	0.58	928
accuracy			0.86	8235
macro avg	0.71	0.87	0.75	8235
weighted avg	0.92	0.86	0.88	8235
ROC-AUC: 0.9359				
PR-AUC: 0.5873				

Отчет по LightGBM (с лучшими параметрами) на валидационной выборке:

	precision	recall	f1-score	support
0	0.98	0.89	0.93	7307
1	0.50	0.84	0.63	928
accuracy			0.89	8235
macro avg	0.74	0.87	0.78	8235
weighted avg	0.92	0.89	0.90	8235
ROC-AUC: 0.9445				
PR-AUC: 0.6550				

Рисунок 3, 4 – Сравнение метрик качества для baseline-модели (Logistic Regression) и продвинутой модели (LightGBM) на валидационной выборке.

5. Финальная оценка и интерпретация модели-победителя

Лучшая модель (LightGBM) была оценена на отложенной тестовой выборке для получения несмещенной оценки ее производительности.

5.1. Результаты на тестовой выборке

1. F1-score (class 1): 0.64;
2. ROC-AUC: 0.9470;
3. PR-AUC: 0.6454.

Финальный отчет по LightGBM на тестовой выборке:

	precision	recall	f1-score	support
0	0.98	0.89	0.93	7308
1	0.51	0.86	0.64	928
accuracy			0.89	8236
macro avg	0.74	0.88	0.79	8236
weighted avg	0.93	0.89	0.90	8236

ROC-AUC: 0.9470
PR-AUC: 0.6454

Рисунок 5 – Финальные метрики качества модели LightGBM на отложенной тестовой выборке.

Результаты на тестовых данных оказались очень близки к валидационным, что свидетельствует об отсутствии переобучения и хорошей обобщающей способности модели.

5.2. Интерпретация модели (Важность признаков)

Для интерпретации предсказаний был использован метод Permutation Importance. Анализ показал, что наибольший вклад в качество модели вносят следующие признаки:

1. **duration**: Длительность последнего телефонного контакта;
2. **euribor3m**: Межбанковская ставка Euribor, отражающая экономическую ситуацию;
3. **emp.var.rate**: Квартальный уровень изменения занятости.

	feature	importance_mean
1	num__duration	0.087470
8	num__euribor3m	0.055767
5	num__emp.var.rate	0.043286
9	num__nr.employed	0.006824
0	num__age	0.001736
44	cat__day_of_week_wed	0.001178
42	cat__day_of_week_thu	0.001044
24	cat__education_high.school	0.000741
30	cat__loan_yes	0.000656
29	cat__housing_yes	0.000546

Рисунок 6 – Важность признаков, рассчитанная методом Permutation Importance.

Наибольшее влияние на предсказание оказывают duration, euribor3m и emp.var.rate.

Это подтверждает гипотезу о том, что поведенческие и макроэкономические факторы являются ключевыми предикторами для данной задачи.

5.3. Анализ ошибок

Найдено 781 ложноположительных ошибок (FP). Примеры:

	age	job	marital	education	default	housing	loan	contact	month	day_of_week	...	previous	outcome
35994	31	blue-collar	single	professional.course	no	no	no	cellular	may	tue	...	0	nonexistent
27173	40	blue-collar	divorced	basic.9y	no	no	no	cellular	nov	fri	...	0	nonexistent
24421	52	admin.	divorced	high.school	no	no	no	cellular	nov	mon	...	0	nonexistent

3 rows x 23 columns

Найдено 128 ложноотрицательных ошибок (FN). Примеры:

	age	job	marital	education	default	housing	loan	contact	month	day_of_week	...	previous	outcome
27704	44	blue-collar	single	professional.course	no	no	no	cellular	mar	mon	...	0	nonexistent
38483	55	unemployed	married	basic.9y	no	no	no	cellular	oct	tue	...	0	nonexistent
30027	64	retired	married	basic.4y	no	yes	no	cellular	apr	wed	...	2	failed

3 rows x 23 columns

Рисунок 7 – Примеры ложноотрицательных срабатываний (FN). Вероятность для первого примера (0.488) близка к порогу классификации 0.5.

Анализ ложноположительных (FP) и ложноотрицательных (FN) срабатываний показал:

1. FP (ложная тревога): Модель склонна ошибочно предсказывать согласие для клиентов с аномально долгими, но безуспешными разговорами;
2. FN (пропуск цели): Самая "дорогая" ошибка. Модель часто упускает клиентов, которые согласились, но не соответствовали типичному "успешному" профилю (например, короткий звонок). Анализ показал, что часть таких ошибок происходит при вероятности, близкой к порогу 0.5.

6. Итоговые выводы

1. В ходе лабораторной работы была успешно построена и оценена модель градиентного бустинга (LightGBM), способная с высокой точностью ($PR-AUC = 0.6454$) прогнозировать отклик клиентов на маркетинговое предложение банка;
2. Доказано, что продвинутая модель LightGBM значительно превосходит базовые подходы (Логистическая регрессия, Дерево решений) для решения данной задачи;
3. Интерпретация модели показала, что ключевыми факторами для прогнозирования являются динамические признаки (длительность контакта, экономические индикаторы), а не статичные демографические данные;
4. Анализ ошибок позволил сформулировать конкретные шаги для дальнейшего улучшения модели: создание новых, более сложных признаков (Feature Engineering) и подбор оптимального порога классификации для минимизации количества "пропущенных" клиентов;
5. Вся работа была выполнена с соблюдением принципов воспроизводимости, включая фиксацию `random_state` и версий библиотек;